

Website Copilot

預建知識庫 × 自主操作代理 — 與特定網站深度整合的 AI 助手

專案規劃 & Phase 1 進度報告 · 2026.06.29

薛耀智

大綱

1. 專案定位

— 背景 · 痛點 · 競品

2. 專案開發

— 目標 · 技術 · 三階段規劃

3. **Phase 1**：資訊檢索

— Crawler → Summarizer → RAG

4. **RAG** 成效評估實驗

— 設計 · 紀錄 · 結論

5. 未來規劃

— Phase 1 收尾 → Phase 2 → Phase 3

專案定位

專案背景

為什麼需要 **Website Copilot** ？

- 網站資訊龐雜，使用者難以快速找到所需資訊
- 網站實際操作輔助不足，使用者自行完成任務效率低

競品分析

類型	代表產品	簡介	限制
AI 客服	Zendesk AI · Intercom Fin AI	基於 LLM 與企業知識庫 進行問答，可串接 API 執 行簡單任務	唯讀策略，無法操作 網站介面
AI Web Agent	Browser Use · Skyvern · LaVague	開源自動化框架，可自主 操作瀏覽器執行表單填寫 等跨頁面任務	即時感知為主，缺乏 事先理解與工作階段 管理
AI 瀏覽 器	Gemini in Chrome · Edge Copilot · Perplexity Comet	內建 AI 助理與工作階段 管理，具備跨分頁理解能 力	通用設計，未針對特 定網站整合，延遲與 成本較高

痛點分析

- 缺乏事先理解 — 執行任務仰賴即時感知，沒有預先理解網站
- 僅止口頭說明 — 解決問題只能提供文字回覆，無法實際協助操作
- 不支援長期互動 — 提供協助侷限在短時間互動，長時間互動穩定性低

專案開發

專案目標

- 預建網站知識庫 — 從局部感知進化至全域掌握
- 賦予網站操作能力 — 從被動問答進化至主動執行
- 導入對話狀態管理 — 從單次協助進化至長期互動

技術分析

借鏡 GitHub Copilot 技術架構


技術面向	說明
全站知識索引&檢索	事先建立全站知識索引，查詢時語意檢索
網站操作能力	使用 MCP 統一整合網站操作工具
代理自動化	將任務拆解執行並動態除錯
對話狀態管理	透過記憶管理與相似度過濾維持對話脈絡

開發規劃

階段	目標	狀態
Phase 1：資訊檢索	網站知識庫 + 語義檢索	 進行中
Phase 2：網站導航	Agent 推理核心 + 網站操作 MCP	未來規劃
Phase 3：專責代理	前端輕量化感知層 + 嵌入式介面	未來規劃

Phase 1：資訊檢索

知識庫建置 workflow



- workflow三階段：爬取網站 → 摘要圖片 → 建置向量索引
- 模組化 workflow：可獨立執行單一模組，亦可全流程自動串接

模組一：Website Crawler

非同步爬取網站、將 HTML 轉為純淨 Markdown，並自動移除導覽列與頁尾等雜訊

進度	說明
非同步爬取	可同時爬取多個頁面，限制網域、深度與頁數避免失控
內容清理	將網頁轉為 Markdown，自動移除導覽列、頁尾等雜訊
平行處理	多個請求並行處理，自動排除重複項目並產出統計記錄

模組二：Image Summarizer

透過 VLM 為網頁圖片產生結構化文字摘要，並寫回至 Markdown 讓純文字檢索也能感知圖片內容

進度	說明
VLM 圖片摘要	用視覺語言模型分析圖片，將結果寫回 Markdown
提示詞迭代	從 v1 基礎描述逐步優化至 v3 可驗證摘要
自動化機制	圖片下載快取、失敗自動重試、指數退避等待

模組三：RAG

將 Markdown 解析切塊後建立向量索引，支援語意檢索與 LLM 問答生成

進度	說明
Markdown 解析與語意切塊	合併空標題並保留標題路徑，確保切塊語意完整
向量嵌入與索引建立	將內容轉為向量並建立索引，支援增量載入既有儲存
語意檢索與問答生成	執行語意檢索搭配 LLM 生成回答，支援相似度門檻過濾

網頁資料處理設計

- **HTML** → **Markdown** — 爬取後轉為 Markdown 並移除雜訊
- **空標題合併** — 將孤立標題併入實質內容節點
- **Metadata 抽離** — 圖片、網址等非文字資訊抽離至 Metadata

RAG 成效評估實驗

實驗設計

- 測試問題：
 - 題目數量：共 5 題
 - 題目類型：指引型・時間範圍型・名單型
- 測試配置：
 - 查詢引擎：`top_k=5, cutoff=0.45, llm=gemini-3.1-flash-lite`
 - 評估工具：`llm=gpt-5.4`
- 測試方式：
 - 查詢：同一個題目重複 10 次查詢
 - 評估：FaithfulnessEvaluator (召回率) + RelevancyEvaluator (準確率)

實驗記錄

類型	範例	穩定度	瓶頸
指引型	加入實驗室所需資料、如何聯絡教授	✓ 100%	有明確且一致的來源支撐，現有配置即可穩定處理
時間範圍型	近三年發表論文、2024年活動	✗ 最不穩定	時間表述未轉為明確年份，檢索易混入不同頁型
名單型	實驗室的成員有哪些人	✗ 檢索失靈	來源含大量 VLM 圖片描述致語義偏移，純向量檢索有本質局限

實驗總結

核心問題

RAG 瓶頸無法靠單一參數解決，是檢索精準度、檢索召回率與生成約束三者的平衡取捨

改善方向

1. 檢索優化 — 導入混合檢索（向量 + BM25 關鍵字），搭配查詢擴展與頁面類型路由
2. 生成約束 — 對名單型、時間範圍類查詢強制要求來源追溯標示

未來規劃

Phase 1 收尾

- **RAG 查詢優化**
 - 導入混合檢索
 - 加入查詢擴展與頁面類型路由
 - 加強來源標示
- **基本 AI 代理**
 - 意圖識別與查詢轉換
 - 支援自然語言問答
- **前端聊天介面**
 - 開發聊天視窗元件
 - 串接 RAG 後端 API

Phase 2 — 網站導航

- **AI** 代理理解自然語言指令
 - 直接控制網站進行頁面跳轉、資料篩選與功能切換

Phase 3 — 專責代理

- **AI** 代理支援使用者客製化
 - 自動完成表單代填、預約等個人化操作