

Website Copilot

預建知識庫 × 自主操作代理 — 與特定網站深度整合的 AI 助手

專案規劃 & Phase 1 進度報告 · 2026.06.29

薛耀智

大綱

1. 專案定位

— 背景 · 痛點 · 競品

2. 專案開發

— 目標 · 技術 · 三階段規劃

3. Phase 1：資訊檢索

— Crawler → Summarizer → RAG

4. RAG 成效評估實驗

— 設計 · 紀錄 · 結論

5. 未來規劃

— Phase 1 收尾 → Phase 2 → Phase 3

專案定位

專案背景

為什麼需要 Website Copilot ?

- 網站資訊龐雜，使用者難以快速找到所需資訊
- 網站實際操作輔助不足，使用者自行完成任務效率低

競品分析

類型	代表產品	簡介	限制
AI 客服	Zendesk AI · Intercom Fin AI	基於 LLM 與企業知識庫進行問答，可串接 API 執行簡單任務	唯讀策略，無法操作網站介面
AI Web Agent	Browser Use · Skyvern · LaVague	開源自動化框架，可自主操作瀏覽器執行表單填寫等跨頁面任務	即時感知為主，缺乏事先理解與工作階段管理
AI 瀏覽器	Gemini in Chrome · Edge Copilot · Perplexity Comet	內建 AI 助理與工作階段管理，具備跨分頁理解能力	通用設計，未針對特定網站整合，延遲與成本較高

痛點分析

- **缺乏事先理解** — 執行任務仰賴即時感知，沒有預先理解網站
- **僅止口頭說明** — 解決問題只能提供文字回覆，無法實際協助操作
- **不支援長期互動** — 提供協助侷限在短時間互動，長時間互動穩定性低

專案開發

專案目標

- **預建網站知識庫** — 從局部感知進化至全域掌握
- **賦予網站操作能力** — 從被動問答進化至主動執行
- **導入對話狀態管理** — 從單次協助進化至長期互動

技術分析

借鏡 GitHub Copilot 技術架構

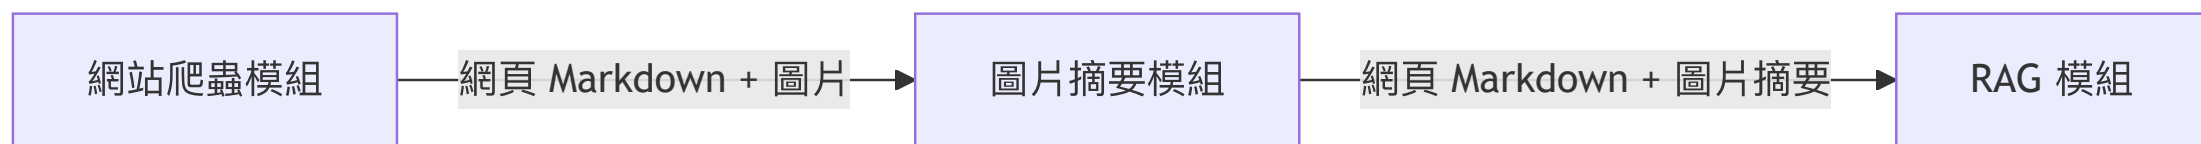
技術面向	說明
全站知識索引&檢索	事先建立全站知識索引，查詢時語意檢索
網站操作能力	使用 MCP 統一整合網站操作工具
代理自動化	將任務拆解執行並動態除錯
對話狀態管理	透過記憶管理與相似度過濾維持對話脈絡

開發規劃

階段	目標	狀態
Phase 1：資訊檢索	網站知識庫 + 語義檢索	 進行中
Phase 2：網站導航	Agent 推理核心 + 網站操作 MCP	未來規劃
Phase 3：專責代理	前端輕量化感知層 + 嵌入式介面	未來規劃

Phase 1：資訊檢索

知識庫建置 workflow



- **workflow三階段**：爬取網站 → 摘要圖片 → 建置向量索引
- **模組化 workflow**：可獨立執行單一模組，亦可全流程自動串接

模組一：Website Crawler

非同步爬取網站、將 HTML 轉為純淨 Markdown，並自動移除導覽列與頁尾等雜訊

進度	說明
非同步爬取	可同時爬取多個頁面，限制網域、深度與頁數避免失控
內容清理	將網頁轉為 Markdown，自動移除導覽列、頁尾等雜訊
平行處理	多個請求並行處理，自動排除重複項目並產出統計記錄

模組二：Image Summarizer

透過 VLM 為網頁圖片產生結構化文字摘要，並寫回至 Markdown 讓純文字檢索也能感知圖片內容

進度	說明
VLM 圖片摘要	用視覺語言模型分析圖片，將結果寫回 Markdown
提示詞迭代	從 v1 基礎描述逐步優化至 v3 可驗證摘要
自動化機制	圖片下載快取、失敗自動重試、指數退避等待

模組三：RAG

將 Markdown 解析切塊後建立向量索引，支援語意檢索與 LLM 問答生成

進度	說明
Markdown 解析與語意切塊	合併空標題並保留標題路徑，確保切塊語意完整
向量嵌入與索引建立	將內容轉為向量並建立索引，支援增量載入既有儲存
語意檢索與問答生成	執行語意檢索搭配 LLM 生成回答，支援相似度門檻過濾

網頁資料處理設計

- **HTML → Markdown** — 爬取後轉為 Markdown 並移除雜訊
- **空標題合併** — 將孤立標題併入實質內容節點
- **Metadata 抽離** — 圖片、網址等非文字資訊抽離至 Metadata

RAG 成效評估實驗

實驗設計

- **測試問題：**
 - 題目數量：共 5 題
 - 題目類型：指引型 · 時間範圍型 · 名單型
- **測試配置：**
 - 查詢引擎：`top_k=5, cutoff=0.45, llm=gemini-3.1-flash-lite`
 - 評估工具：`llm=gpt-5.4`
- **測試方式：**
 - 查詢：同一個題目重複 10 次查詢
 - 評估：FaithfulnessEvaluator (召回率) + RelevancyEvaluator (準確率)

實驗記錄

類型	範例	穩定度	瓶頸
指引型	加入實驗室所需資料、 如何聯絡教授	✓ 100%	有明確且一致的來源支撐，現有配置即可穩定處理
時間範圍型	近三年發表論文、2024 年活動	✗ 最不 穩定	時間表述未轉為明確年份，檢索易混入不同頁型
名單型	實驗室的成員有哪些人	✗ 檢索 失靈	來源含大量 VLM 圖片描述致語義偏移，純向量檢索有本質局限

實驗總結

核心問題

RAG 瓶頸無法靠單一參數解決，是**檢索精準度**、**檢索召回率**與**生成約束**三者的平衡取捨

改善方向

1. **檢索優化** — 導入混合檢索（向量 + BM25 關鍵字），搭配查詢擴展與頁面類型路由
2. **生成約束** — 對名單型、時間範圍類查詢強制要求來源追溯標示

未來規劃

Phase 1 收尾

- **RAG 查詢優化**
 - 導入混合檢索
 - 加入查詢擴展與頁面類型路由
 - 加強來源標示
- **基本 AI 代理**
 - 意圖識別與查詢轉換
 - 支援自然語言問答
- **前端聊天介面**
 - 開發聊天視窗元件
 - 串接 RAG 後端 API

Phase 2 — 網站導航

- AI 代理理解自然語言指令
 - 直接控制網站進行頁面跳轉、資料篩選與功能切換

Phase 3 — 專責代理

- AI 代理支援使用者客製化
 - 自動完成表單代填、預約等個人化操作