

Website Copilot

Phase 2/3 MVP : AI Agent × 聊天介面

專案進度報告 · 2026.08.12

薛耀智

大綱

1. 背景與目標

— 承接上次進度 · 端到端 MVP

2. Phase 2 : AI Agent

— 選型 · LangGraph 問答 · 多輪記憶 · 串流

3. Phase 3 : 聊天介面

— 選型 · FastAPI SSE · 三種嵌入表面 · Chrome Extension

4. 端到端成果

— 架構總覽 · 驗證指標達成

5. 未來規劃

— 對話累積 · 成本優化 · MCP Server

背景與目標

- **上次進度**：RAG Retriever Tool 已包裝為 `StructuredTool`，**Agent 整合是下一步**。
- **MVP 目標**：RAG 工具 → Agent → 可嵌入網站的聊天介面

Phase 2 : AI Agent

選型：Agent 框架

採用 LangGraph

方案	取捨
A. LangGraph 	<code>StructuredTool</code> 直接支援、快速建立 Agent、內建串流 / 記憶
B. LlamaIndex AgentWorkflow	Tool 介面需轉接，偏離路線
C. 手工 ReAct 迴圈	自建 tool_calls 解析 / 重試 / 串流，複雜度高

Agent 設計

- **工具整合**：LangGraph `create_agent` 包裝 `webpage_retriever`，LLM 自主決定檢索時機與參數（`query` / `filter_dict`）
- **串流輸出**：`astream` 逐 token 顯示（`--run.stream`），回答即時呈現
- **回覆機制**：回答附檢索來源 URL，對話紀錄儲存至 `chats/<ts>/agent/`
- **多輪記憶**：`InMemorySaver` + `thread_id`，同 thread 連續追問記得上下文

Phase 3：聊天介面

選型：聊天介面

採用 FastAPI + SSE + 單頁前端

方案	取捨
A. FastAPI + SSE 	輕量可控，方便 Phase 3 正式版移植
B. Chainlit	現成 UI 但依賴重、客製受限
C. Gradio / D. LangGraph Platform	聊天體驗一般 / 對最小實證過重

API設計

- **SSE 事件協定**： `token`（逐 token 文本） / `done`（完整回應 + thread_id 續接多輪） / `error`（錯誤訊息）
- **Session 管理**：thread_id 由 server 自動產生（`auto-{uuid}`），前端可重新呼叫持續 session
- **資源生命週期**：agent 和工具於 server 啟動時建一次，並在關閉時釋放

網頁嵌入設計

- **iframe 嵌入**：一行 `<iframe>` 嵌入完整聊天頁
(`http://localhost:8000/static/chat.html`)
- **script widget 嵌入**：一行 `<script>` 在任何頁面右下角浮動  對話框 (`data-endpoint` 指定後端)
- **Chrome 擴充功能**：content script 注入 widget 到任何網站，由 background worker 代理 fetch 後端 SSE (繞過網頁 CORS / CSP)

端到端架構

```
flowchart LR
    subgraph Surface [介面嵌入]
        A1[iframe] --- A2[widget.js]
        A2 --- A3[Chrome Extension]
    end
    A1 --> B[FastAPI + SSE<br/>POST /api/chat]
    B --> C[LangGraph Agent<br/>InMemorySaver + thread_id]
    C --> D[webpage_retriever<br/>StructuredTool]
    D --> E[Milvus 混合檢索<br/>BGE-M3 + WeightedRanker]
    E --> F[知識庫<br/>爬蟲 + 圖片摘要 + Metadata]
    C --> G[回答附來源 URL]
    G --> H[落盤 chats/]
```

MVP 成果總結

1. **檢索**：網站知識庫 + 混合檢索，組合為檢索工具
2. **推理**：LangGraph Agent 補上多輪記憶與串流，會檢索、附來源
3. **介面**：FastAPI SSE + iframe/widget/Chrome Extension 可以嵌入任何網站

未來規劃

Phase 2 進階

- Agent 工具包裝為 **MCP Server**
- 工具調用成本優化

前台 Copilot 功能

- 進階資料檢索 · Context / Memory Management
- 使用者個人化學習 · COT / Tree of Thoughts

後台 Copilot 功能

- 功能優化 · 錯誤處理