

Website Copilot

多站知識庫：從單站檢索到自動路由

專案進度報告 · 2026.08.26

薛耀智

大綱

1. 背景與目標

— 承接上次進度 · 多站架構升級

2. HTML 日期擷取

— 六層解析 · 日期 metadata 注入

3. 多站 RAG 檢索工具

— RAGRegistry · 多站路由 · 站點發現

4. Chrome Extension 站點偵測

— 自動偵測 · 後端映射 · 使用者無感路由

5. 實作成果

— 架構總覽 · 兩站驗證

背景與目標

- **上次進度**：Agent + 聊天介面 MVP 完成，但所有功能硬綁**單一網站**（nculab）
- **核心問題**：爬蟲設定、資料目錄、向量庫、Agent 工具全部指向單站，缺乏多站隔離
- **本次目標**：建立**多站知識庫**架構，讓 Agent 可根據使用者瀏覽的網站自動路由至對應知識庫

HTML 日期擷取

日期擷取

原先時間 metadata 僅靠文字推斷 → 改為爬蟲階段從 HTML 結構化標籤擷取

優先級	來源
1	JSON-LD <code>datePublished</code>
2	OG <code>article:published_time</code>
3	<code><time datetime></code> 元素
4	Generic meta <code>date</code> / <code>pubdate</code>
5	Dublin Core <code>dc.date</code>
6	HTTP <code>Last-Modified</code>

無資料時 fallback 至原有文字推斷策略，完全向後相容。

nculab / ncucsie 無法擷取日期

站點	平台	結果	原因
nculab	Google Sites	✗	SPA 架構，HTML 中完全沒有 JSON-LD、OG meta、 <code><time></code> 等結構化日期標籤
ncucsie	自架 PHP 站	✗	無結構化日期標籤，伺服器也不回傳 <code>Last-Modified</code> 標頭

HTML 日期擷取的有效性高度依賴網站平台（WordPress、Medium 等有 SEO 套件的網站才有效）。

對 nculab / ncucsie，仍依賴 `MarkdownDateExtractor` 文字推斷作為主要日期來源。

多站 RAG 檢索工具

問題

Agent 工具層硬綁**單一 RAG 實例**，無法同時存取多站知識庫。

解法

組件	功能
RAGRegistry	多站 RAG 實例管理：lazy + LRU 快取（上限 5）
webpage_retriever	新增 <code>site_id</code> 必要參數，依 site_id 路由至對應 RAG
list_knowledge_bases	站點發現工具，回傳所有可用 site_id

Chrome Extension 站點偵測

自動路由

Extension 偵測當前 URL → 後端映射 → LLM 自動帶入 site_id

- `content.js` 偵測 `window.location.hostname`
- → `background.js` 透傳 `page_url` 至 Server
- → Server `resolve_site_id()` 映射為 site_id
- → `_enrich_query()` 前綴 [使用者瀏覽 nculab 網站] 至 user query
- → LLM 自動帶入 site_id → `RAGRegistry` 路由至正確知識庫

使用者**無感切換**——開啟哪個學校的頁面，Agent 就查哪個知識庫。

三種介面共用路由

介面	site_id 來源
Chrome Extension	<code>window.location.hostname</code> → 後端 <code>DOMAIN_SITE_MAP</code> 映射
CLI	<code>--site-id</code> 手動指定
Server API	請求參數 <code>page_url</code> (可選)

Service Worker Keepalive : `chrome.alarms` 每 25 秒觸發，解決切站時連線中斷問題。

實作成果

架構總覽

- **Chrome Extension** : `content.js` 偵測 hostname → `background.js` 透傳至 Server
- **FastAPI Server** : `resolve_site_id()` 映射 → `_enrich_query()` 注入 site 語境
- **LangGraph Agent** : 多輪記憶 + SSE 串流，自動選擇 `webpage_retriever(site_id)`
- **RAGRegistry** : LRU 快取管理多站 RAG 實例 → 路由至 Milvus nculab / ncucsie

兩站驗證結果

指標	nculab	ncucsie
爬蟲	✓ 334 KB	✓ 396 KB
圖片摘要	✓	✓
RAG 建庫	✓ Milvus	✓ Milvus
資料隔離	✓ 獨立目錄	✓ 獨立目錄
Agent 問答	✓ 正確回覆	✓ 正確回覆

成果總結

1. **日期擷取**：六層 HTML 解析 + fallback，為 node metadata 注入時間資訊
2. **多站 RAG**：RAGRegistry + LRU 快取，Agent 可根據 site_id 路由至正確知識庫
3. **自動路由**：Extension 偵測 hostname → 後端映射 → query 前綴，使用者無感切換